

Práctica II

2025

Enunciado

- La práctica debe entregarse antes del **28 de noviembre de 2025**.
- El resultado final deberá incluir un fichero *Jupyter Notebook* (.ipynb) y los ficheros .py correspondientes.
- Cada ejercicio debe resolverse en una celda independiente. Puede utilizarse un único bloque de código o una única función por ejercicio, aunque también es posible definir funciones adicionales si se considera oportuno.
- Se debe realizar un **git commit** por cada apartado de cada ejercicio. Una vez completado el trabajo, desde la terminal se deberá ejecutar el siguiente comando:

```
git log > log.txt
```

Este comando generará un fichero `log.txt`, que también deberá subirse junto con el resto de archivos de la práctica.

Ejercicios

1. Creación de *DataFrames*

- (a) Crea un `DataFrame` `df1` con una columna llamada `numeros` que contenga los valores del 0 al 19.
- (b) Crea un `DataFrame` `df2` con una columna `aleatorios` de tamaño 10 con números aleatorios entre 0 y 1.
- (c) Combina los `DataFrames` anteriores `df1` y `df2` en un nuevo `DataFrame` llamado `df3`.
- (d) Guarda el `DataFrame` `df3` en un fichero `.csv`.

2. Indexación y selección (10 pts)

Dado el DataFrame:

```
1 import pandas as pd
2 df = pd.DataFrame({
3     "A": range(1, 11),
4     "B": [5,3,6,8,2,9,1,7,4,10]
5 })
```

- (a) Selecciona las filas donde el valor de la columna B sea mayor que 5.
- (b) Cambia los valores menores que 4 en la columna B a NaN. Para usar el valor NaN hay que utilizar el código `pd.NA`.

3. Análisis de Datos

Descargad el conjunto de datos disponible en la siguiente página web y utilizad el fichero `winequality-red.csv`. Este dataset contiene información físico-química sobre diferentes vinos tintos de Portugal.

Se pide:

- (a) Obtén los estadísticos descriptivos más relevantes (*describe*) de cada columna. Explica brevemente qué mide cada una de ellas.
- (b) Convierte la columna `quality` en una columna categórica con tres categorías:
 - **bueno**
 - **regular**
 - **malo**
- (c) Selecciona los vinos clasificados como *malo* y elimínalos del `DataFrame`.
- (d) Convierte los valores de la columna `citric acid` a porcentajes.
- (e) Obtén los siete vinos con mayor valor de pH.

Ahora crea un fichero `.py` que defina las siguientes funciones:

- (a) `eliminaDecimales(df, col)`: recibe un `DataFrame` y el nombre de una columna, y crea una nueva columna llamada `<col>_sin_decimales` con el mismo valor pero truncado (sin decimales).
- (b) `calculaRatio(df, col1, col2)`: calcula el ratio entre dos columnas y genera una excepción si algún valor del ratio es mayor que 1.

Aplica la primera función a la columna `alcohol` y la segunda a las columnas `total sulfur dioxide` y `free sulfur dioxide`.

4. Combinando información en pandas

Dispones de los siguientes DataFrames:

```
1 import pandas as pd
2
3 estudiantes = pd.DataFrame({
4     "id": [1, 2, 3, 4],
5     "nombre": ["Ana", "Luis", "Marta", "Jorge"]
6 })
7
8 notas = pd.DataFrame({
9     "id": [1, 2, 2, 5],
10    "asignatura": ["Matemáticas", "Historia", "Química", "Biología"],
11    "nota": [8.5, 7.0, 6.5, 9.0]
12 })
```

Realiza las siguientes tareas:

- Realiza un `merge` interno (*inner*) entre ambos DataFrames. ¿Cuántas filas se obtienen? ¿Por qué?
- Realiza un `merge` externo (*outer*). Explica las filas que aparecen con valores nulos.
- Realiza un `left merge` usando `estudiantes` como tabla izquierda. ¿Qué información se pierde respecto al `outer`?
- Realiza un `right merge` usando `notas` como tabla derecha. ¿Qué estudiantes desaparecen en el resultado?
- Añade una columna llamada `curso` al DataFrame `estudiantes`. Después, combina los datos utilizando un `merge` múltiple por `id` y explica el resultado.

5. Agregaciones y operaciones con groupby

En este ejercicio se trabajará con un conjunto de datos que contiene información sobre ventas realizadas por una empresa en distintas regiones.

Considera el siguiente DataFrame:

```
1 import pandas as pd
2
3 ventas = pd.DataFrame({
4     "region": ["Norte", "Norte", "Sur", "Este", "Sur", "Este", "Oeste",
5               "Oeste", "Norte", "Sur"],
6     "vendedor": ["Ana", "Luis", "Ana", "Jorge", "Luis", "Ana", "Marta",
7                 "Luis", "Ana", "Jorge"],
8     "ventas": [1200, 800, 950, 1100, 400, 1600, 700, 450, 895, 900],
9     "producto": ["A", "A", "B", "A", "B", "A", "B", "A", "B", "B"]
10 })
```

Realiza las siguientes tareas:

- Obtén el total de ventas por región.
 - Calcula la media, el valor máximo y el mínimo de las ventas agrupadas por vendedor.
 - Calcula el número de ventas realizadas por cada combinación de **region** y **producto**.
 - Crea una función llamada **rango_ventas** en un fichero **.py** que calcule la diferencia entre el valor máximo y mínimo de un grupo. Aplícala a las ventas agrupando por región.
 - Identifica la región con el mayor número total de ventas y muestra solo esa región.
6. **Gestión de datos ausentes.** Utilizando los mismos datos que en el ejercicio cuatro realiza un **merge** por la izquierda, siendo el primer elemento el DataFrame con la información de estudiantes y el segundo elemento el DataFrame de notas.
- Cuenta cuantos NaNs aparecen en cada columna.
 - Propón dos estrategias diferentes para tratar los NaNs del DataFrame resultantes y aplica estás estrategias. Justifica las estrategias.